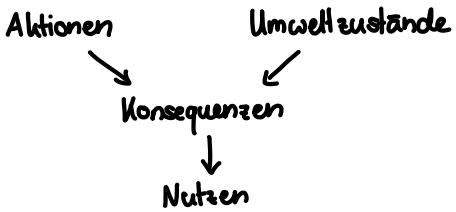


Einführung



- aleatoric: Unsicherheit in Systemen, die wirklich zufällig sind (Lotterie, Würfel,...)
- epistemic: Wissensbezogen; Unsicherheit kommt daher, dass ich etwas nicht weiß (z.B. wurde mein Paket geliefert?)

Grundlegende Einschränkungen:

- Homogene Entscheidungsträger
- Einmalige Entscheidung (kann aus vielen Einzelentscheidungen bestehen)
- mehrere Umweltzustände (bei nur einem → Lösung klar)

Grundlagen

Verschiedene Typen von Unsicherheiten

- Typ I Umweltzustände sind das Ergebnis eines perfekten Zufallsmechanismus mit bekannter Wktsvlg. → „Lotterien“
- Typ I' Entscheidungsträger kann subjektive Wkt. für die Zustände angeben (Bayes-Entscheidungssituation)
- Typ II Umweltzustände durch Handlungen eines feindlichen Gegenpielers erzeugt
- Typ II' Unsicherheitssituation im strengen Sinn „Ungewissheitssituation“ (man kann keine Wkts angeben)

wenn wir keine Wkt. angeben können nehmen wir sie an
aber die Spieltheorie (ungenau!)

↪ klassische Entscheidungstheorie: behandle I' wie I und II' wie II

Datenfreies Entscheidungsproblem

$$\begin{array}{lll}
 \text{Aktionenmenge} & \text{Zustandsmenge} & \text{Nutzenfunktion: } u: A \times \Theta \rightarrow \mathbb{R} \\
 \text{Nutzenform } \{a_1, \dots, a_i, \dots, a_n\} (A, & \Theta, \{v_1, \dots, v_j, \dots, v_m\} \text{ zu } u(\cdot)) & (a, v) \mapsto u(a, v) \\
 \text{Verlustform} & \text{Verlustfunktion} & \\
 & (A, \Theta, l(\cdot)) & \text{Konsequenzfkt.} \\
 \end{array}$$

Man spricht von einem Entscheidungsproblem, wenn gilt:

- 1) A sei bekannt
- 2) Θ sei bekannt (Closed-World-Assumption)
- 3) Die Ergebnisse / Konsequenzen sind eindeutig.
Dabei können Konsequenzen durchaus Wktsvlg. sein.
- 4) Es lässt sich eine eindeutig bestimmte reellwertige Nutzen-/Verlustfkt. angeben, die die individuellen Präferenzen des Entscheidungsträgers vollständig widerspiegelt.

manchmal als Zwischenschritt sinnvoll

$$\begin{array}{c}
 \text{Konsequenzfkt. } \downarrow A \times \Theta \rightarrow C \\
 u(a, v) = u_c(c(a, v)) \\
 C \rightarrow R \quad \text{Nutzenbewertung}
 \end{array}$$

- Nutzentheorie: Konstruktion von Nutzenfkt. aus Präferenzordnungen

→ Annahme: vollständige Ordnung der Präferenzen möglich → eindimensional

↪ keine untersch. nichtabbildbaren „Nutzendimensionen“ (mehrdimensionale Nutzenbewertungen)

- Nutzen wird als abstrakte Größe gesehen (Wertdispositionen sind mit integriert)

- Vorsicht: Nutzen ≠ Geldmenge (Nutzenfkt. nicht unbedingt linear in Geldbeträgen)

- 5) Aktionen und Zustände sind wertfrei
- 6) Typ (I, I', II, II') der Unsicherheit ist bekannt
- 7) Keine zusätzliche Information (Informationsgewinn über strategien formulieren)
- 8) Umwelt nicht beeinflussbar: Handlungsunabhängigkeit der Zustände
- 9) Einmalige Wahl der Entscheidung
- 10) Keine Wiederholung der Entscheidungssituation (sonst als Entscheidungsstrategie formulieren)

TYPISCHE BEISPIELE

Omelettenproblem von Savage → Ziel: Omelett essen; 6 Eier, 1 davon vlt. schlecht

Aktionen	ϑ_1 : Ei gut	ϑ_2 : Ei schlecht	Umweltzustände
A1 Ei verwenden	12	-12	
A2 Ei überprüfen	10	6	Nutzen
A3 Ei wegwerfen	8	8	
A4 Ei kaputt machen	2	2	→ stark/strikt dominiert

Ausflugsproblem nach Chernoff & Moses → Ziel: Bergwanderung; Wetter könnte plötzlich schlecht werden

	ϑ_1 : gutes Wetter	ϑ_2 : schlechtes Wetter
a1 leichte Kleidung	5	0
a2 -" + ☂	3	1
a3 wetterfeste Kleidung	2	-3

EINbettung statistischer Tests

	ϑ_0 : H_0 richtig	ϑ_1 : H_1 richtig	
a1 für H_0 entscheiden	0	c_1	
a2 für H_1 entscheiden	c_2 ↪ Verluste untersch. groß	0	Verluste

Randomisierte Aktionen

randomisierte (gemischte) Aktion

$$(A, \sigma(A)) = M(A)$$

$$\tilde{a}(\{\alpha_i\}) \in M(A)$$

$$\tilde{a} = \begin{bmatrix} a_1 & a_2 & \dots & a_n \\ \tilde{a}(\{\alpha_1\}) & \tilde{a}(\{\alpha_2\}) & \dots & \tilde{a}(\{\alpha_n\}) \end{bmatrix}$$

mögliche Aktionen
Wahlwahrscheinlichkeiten

↪ Nutzen/Verlust muss noch definiert werden (z.B. als Erwartungswert)

gemischte Erweiterung

$$(M(A), \oplus, \tilde{u}(\cdot))$$

$$\tilde{u}(\cdot): M(A) \times \Theta \rightarrow \mathbb{R}$$

$$(\tilde{a}, \vartheta) \mapsto \tilde{u}(\tilde{a}, \vartheta)$$

↪ $\tilde{u}(\tilde{a}, \vartheta) := E_{\tilde{a}}[u(a, \vartheta)]$ \mathbb{E} bzgl. der Aktionen

⇒ lässt sich also wie ein „normales“ datenfreies Entscheidungsproblem behandeln

reine Aktion

$$\tilde{a}(\cdot) = \delta_{\{\alpha_i\}} \rightarrow \text{Wkt. 1}$$

Datengestützte Entscheidungstheorie

Entscheiden auf Datenbasis

- Abbildung der Daten in die ursprüngliche Aktionenmenge
 - ↪ überlegen, bevor man Daten geschenkt hat

„wenn ... , dann Aktion ...“

Informationsbeschaffungsexperiment = Informationsstruktur

liefert unsichere Information (als Wahlen)

die Wahlen sind abhängig von den Umweltzuständen

	x_1	x_2	x_3
v_1	0.6	0.3	0.1
v_2	0.2	0.4	0.4
v_3	0.1	0.4	0.5

Likelihood

allgemein:

	x_1	x_2	x_3
v_1	$p_{v_1}(X=x_1)$	$p_{v_1}(X=x_2)$	$p_{v_1}(X=x_3)$
v_2	$p_{v_2}(X=x_1)$	$p_{v_2}(X=x_2)$	$p_{v_2}(X=x_3)$
v_3	$p_{v_3}(X=x_1)$	$p_{v_3}(X=x_2)$	$p_{v_3}(X=x_3)$

↪ probabilistische Struktur sei bekannt

Entscheidungsfunktion

wenn x beobachtet wird, wählt man Aktion $d(x)$
 $d: X \rightarrow A$; $x \mapsto d(x)$

Wertebereich des Informationsbeschaffungsexperiments

↪ Ziel: für beste Entscheidungsfkt. entscheiden

Menge von Entsch.fkt.

Erwarteter Nutzen

$U: D \times \Theta \rightarrow \mathbb{R}$

$$(d, \vartheta) \mapsto U(d, \vartheta) = \mathbb{E}_{p_{\vartheta}} u(d(x), \vartheta)$$

Erwartungswert bzgl. der \underline{x}

Datengestütztes Entscheidungsproblem

↪ auch nur Spezialfall: Aktionen sind versch. Entsch.fkt., Nutzen sind Erwartungswerte

$$((A, \Theta, u(\cdot)), (X, \sigma(X), (p_{\vartheta})_{\vartheta \in \Theta}))$$

datenfreies Entscheidungsproblem Informationsstruktur

$$\begin{array}{ll} \text{Aktionen} & \text{Risikofkt.} \\ \downarrow & \downarrow \\ (D, \Theta, U) & (D, \Theta, R) \\ \text{Nutzenform} & \text{Verlustform} \end{array}$$

Randomisierte Entscheidungsfunktionen

1. Möglichkeit: „echte randomisierte Entscheidungsfkt.“

$$A \rightarrow D \rightarrow M(D)$$

ausgeschließlich
keine Aktionen es wird zwischen
Entsch.fkt. randomisiert

2. Möglichkeit: „behavioristische Entscheidungsfkt.“

$$A \rightarrow M(A) \rightarrow D(M(A))$$

es wird zwischen
Aktionen randomisiert

Beim eingebetteten Schätzproblem bringt unter Regularitätsbedingungen Randomisieren keine Verbesserung

Grundstruktur

$$\begin{array}{c} \text{Aktionen-} \\ \text{Zustandsmenge} \end{array} \xrightarrow{\text{Nutzen-}} \text{funktion}$$

$$(A, \Theta, u)$$

mit $u: A \otimes \Theta \rightarrow \mathbb{R}$

Datengestützt

Entscheidungs- Gain-funktion

$$(D, \Theta, U)$$

mit $U: D \otimes \Theta \rightarrow \mathbb{R}$.

$$(d, \vartheta) \mapsto \mathbb{E}_{p_{\vartheta}} (u(d(\cdot), \vartheta))$$

Randomisiert

Wahrscheinlichkeitsmaße auf

$$(M(A), \Theta, \tilde{u})$$

mit $\tilde{u}: M(A) \otimes \Theta \rightarrow \mathbb{R}$,

$$(A, \vartheta) \mapsto \mathbb{E}_\vartheta (u(\cdot, \vartheta))$$

- Flexible Verlustfkt. → Verallgemeinerung möglich (z.B. Überschätzung als Unterschätzung)

- stetiges p_{ϑ} und hinreichend reguläre Verlustfkt. → beim Schätzen kann auf Randomisieren verzichtet werden

- Möglichkeiten Dimensionen zu reduzieren?

- Reihenfolge nicht beachten

- Summe der Einzelergebnisse

- Suffiziente Statistik

Entscheidungstheorie	Klassische Schätztheorie	Testtheorie	Regression
Zustandsraum	Parameterraum	H_0 und H_1	wahrer Zusammenhang
Zustand	Parameterwert	H_0, H_1	Zusammenhang zwischen y und x
Aktion	Schätzwert (1 Zahl)	Testentscheidung	Schätzer der Parameter
Verlustfunktion	$(\theta - \hat{\theta})^2$	$\begin{matrix} 0 & 1 \\ 1 & 0 \end{matrix}$	Abstand Schätzer vom wahren Wert
Informationsstruktur	Verteilung der SP	Verteilung der SP	Verteilung der SP (gemeinsam)
Entscheidungsfkt.	Schätzfunktion	Testfkt. / Kritische Region	KQ-Schätzer
Risikofunktion (IE der Verlustfunktion)	Varianz, MSE	Fehlerwkt 1./2. Art	Bestimmtheitsmaß

Entscheidungskriterien

Entscheidungsprinzipien

- Grundsätze für die Auswahl von Aktionen
- beanspruchen allgemeine Rationalitätsprinzipien zu sein \rightarrow geringe Ordnungskraft
- unabhängig vom Unsicherheitsverständnis (Typ I oder Typ II)

Dominanz

Seien $a_1, a_2 \in A$

- a) a_1 dominiert $a_2 \Leftrightarrow u(a_1, v) \geq u(a_2, v)$ für alle $v \in \Theta$ $a_1 \succeq a_2$ größer gleich
- b) a_1 dominiert a_2 strikt $\Leftrightarrow u(a_1, v) \geq u(a_2, v)$ für alle $v \in \Theta$
und $u(a_1, v) > u(a_2, v)$ für min. ein $v \in \Theta$ $a_1 \succ a_2$ min 1 größer
- c) a_1 dominiert a_2 stark $\Leftrightarrow u(a_1, v) > u(a_2, v)$ für alle $v \in \Theta$ $a_1 \succcurlyeq a_2$ überall größer
- d) a_1, a_2 sind äquivalent $\Leftrightarrow a_1 \succeq a_2$ und $a_2 \succeq a_1$ $a_1 \sim a_2$ genau gleich

Admissibilität / Zulässigkeit

$a \in A$ heißt zulässig $\Leftrightarrow a$ wird von keiner Aktion strikt dominiert

\rightarrow Menge aller zulässigen Aktionen $A_{ad} := \{a \in A \mid \exists a^* \in A : a^* \succ a\}$ (für endliches A immer min. 1 Aktion)

Dominanzprinzip: Es ist nicht vernünftig, eine inadmissible (nicht zulässige) Aktion zu wählen.

Vollständige Klassen

Problem: A_{ad} oft nicht bestimmbar

→ Idee: Obermenge, die zumindest etwas einschränkt und alle zulässigen Aktionen enthält

a) Eine Teilmenge $C \subseteq A$ heißt **vollständig** \Leftrightarrow alle Elemente außerhalb der Menge werden von einem Element in der Menge strikt dominiert

b) Eine Aktionenmenge $C \subseteq A$ heißt **wesentlich vollständig** \Leftrightarrow alle Elemente außerhalb der Menge werden von einem Element in der Menge dominiert

→ minimal vollständige Klasse $C_{min} = A_{ad}$

Entscheidungsregeln / Optimalitätskriterium

- Entscheidungsregeln induzieren eine **vollständige** und **transitive** Ordnung auf der Aktionenmenge A

ordnungsbar $a > b \wedge b > c \Rightarrow a > c$

- konkrete Regeln, hängen vom Unsicherheitsverständnis ab

- weist den Aktionen reelle Zahlen zu
→ Ordnen möglich

$\Phi : A \rightarrow \mathbb{R}^q$; $a \mapsto \Phi(a)$
 $\hookleftarrow \geq 2 \rightarrow$ lexicographische
Ordnung
Suche $a^* \in A$ mit $\Phi(a^*) \geq \Phi(a) \quad \forall a \in A$
 $\Rightarrow a^*$ ist dann Φ -optimale Aktion

MINIMAX - Entscheidungen

- Annahme: Typ II - Unsicherheit (feindlicher Gegenspieler)

→ keine Wissensaussagen über Umweltzustände nötig

- Randomisieren kann zu Verbesserung führen

- „wir rechnen damit bei jeder Aktion den minimalen Nutzen zu bekommen“
↳ dieses Minimum maximieren wir

- lediglich die Ordnung des Nutzens ist relevant → invariant gegenüber monotonen Transformationen

- zur Berechnung meist lineare Optimierung nötig

- A endlich + \mathbb{R} endlich \Rightarrow es existiert Maximin Aktion in A und $M(A)$

a) Nutzenform: $a^* \in A$ Maximin-Aktion $\Leftrightarrow \inf_{v \in \Theta} u(a^*, v) \geq \inf_{v \in \Theta} u(a, v) \quad \forall a \in A$

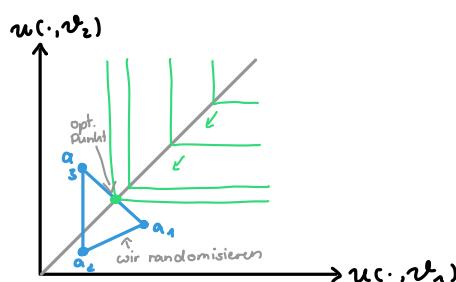
b) Verlustform: $a^* \in A$ Minimax-Aktion $\Leftrightarrow \sup_{v \in \Theta} l(a^*, v) \leq \sup_{v \in \Theta} l(a, v) \quad \forall a \in A$

damit wählt man die Kriteriumsfunktion

$\Phi : A \rightarrow \mathbb{R}; a \mapsto \inf_{v \in \Theta} u(a, v)$

$a \mapsto -\sup_{v \in \Theta} l(a, v)$

Graphische Bestimmung:



EQUALIZER - Aktion

- Äquilibrator-Aktion

- in v konstantem Nutzen

- liegt auf Winkelhalbierendem

- falls zulässig → Minimax-Aktion

Bayes - Entscheidungen

Erwartungsnutzen

$$E_{\pi}(u(a)) := \int_{\Theta} u(a, \vartheta) d\pi(\vartheta)$$

Wahrscheinl. der Umweltzustände

Bernoulli-Kriterium: wähle $\tilde{\Phi}(a, \pi) = E_{\pi}(u(a))$ als Kriteriumsfkt.

↪ ideale Risikosituation (π gegeben) **OBJEKTIVE WERTSBEWERTUNG**

Einbeziehen der Varianz

- 1) Zweistufige (μ, σ) -Kriterien um zwischen Aktionen mit gleichem E zu differenzieren
- 2) Einstufige (μ, σ) -Kriterien $\tilde{\Phi}(a) = E_{\pi}(u(a)) - c \cdot \sqrt{V_{\pi}(u(a))}$
 ↪ Ergebnis mögl. dominiert
 $c > 0$ risikoavers (Bestrafung für hohe Streuung)

Jede Situation unter Unsicherheit kann durch einen Wahrscheinlichkeitsraum (Ω, \mathcal{F}, P) beschrieben werden

? Bayesianisches Paradigma

a priori Verteilung (Verteilung „vor den Daten“) π

Bayes Nutzen

Bayes - Kriterium $\tilde{\Phi}(\cdot, \pi) : A \rightarrow \mathbb{R}$, $a \mapsto \tilde{\Phi}(a, \pi) := E_{\pi}(u(a)) = \int_{\Theta} u(a, \vartheta) d\pi(\vartheta)$
SUBJektive WERTSBEWERTUNG

Wichtige Sätze über Bayes-Aktionen:

a) Entbehrlichkeit randomisierter Aktionen

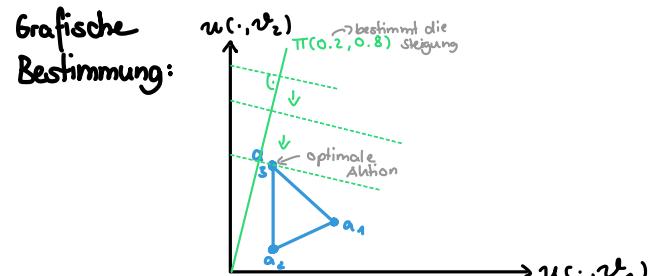
Es gibt immer auch eine reine Aktion, die Bayes-Aktion ist
 → Randomisieren lohnt sich nicht

b) Jede Bayes-Aktion ist zulässig

Außerdem: Zu jeder zulässigen Aktion a gibt es eine a priori Vtg $\pi^a(\cdot)$, so dass a Bayes-Aktion zur Bewertung $\pi^a(\cdot)$ ist

c) Bayes und Minimax

Eine Äquilibrator-Aktion, die zugleich Bayes-Aktion ist, ist auch Minimax-Aktion



Theorem von Bayes

Zufallsvariablen
 $f_{U|x}(u|x) = \frac{f_{X|U}(x|u) \cdot f_U(u)}{f_X(x)}$, $f_X(x) = \int f_{X|U}(x|u) f_U(u) du$
 „proportional zu“

$$f_{U|x}(u|x) \propto f_{X|U}(x|u) \cdot f_U(u)$$

→ sobald ich eine gemeinsame Vtg. anerkenne, folgt daraus Bayesianische Inferenz

$$\pi(u|x) \propto f_U(u) \cdot \pi(u)$$

Konditionale Bayes-Inferenz

bisher a priori Vtg. der Umweltzustände

↪ ab jetzt wird mit Posteriori-Vtg gearbeitet → Datenbasiert

Posteriori-Verlust optimale Aktion / konditionale Bayes-Aktion

Beobachtung (Infobeschaffungsperiment)

$$a_x^* \in A$$

$$E_{\pi(\cdot|x)} \ell(a_x^*, \vartheta) \leq E_{\pi(\cdot|x)} \ell(a, \vartheta) \quad \forall a \in A$$

HAUPTSATZ DER BAYES-ENTScheidungstheorie

datenfreies Problem Informationsstruktur Priori-Vtlg.
 geg.: $(A_1, \otimes, \ell(\cdot))$, $(X, \mathcal{U}, (\mu_x)_{x \in X})$, $\pi(\cdot)$

BAYES-OPTIMALE AKTION

alle möglichen Entschl. + Prioritlg.



Bayes-optimale Entschl. $a^*: X \rightarrow A_1$
 + konkrete Beobachtung x



Bayes-optimale Aktion $a_x^* = a^*(x)$

POSTERIORI-VERLUST OPTIMALE AKTION

Posteriori-Vtlg.



Posteriori-Verlust optimale Aktion a_x^*

Entschl. $a^*: X \rightarrow A_1$, $x \mapsto a^*(x)$ ist Bayes-optimal $\Leftrightarrow \forall x \in X$ ist die zugehörige Aktion $a^*(x)$ Posteriori-Verlust optimal zur Beobachtung x ist.

→ beide Wege sind äquivalent (wir kriegen selbes Ergebnis)
 ↳ aber Posteriori ist deutlich einfacher

ALTERNATIVE REGELN

LAPLACE REGEL

Problem: Bayes kann kritisch gesehen werden

- > entweder: so viele Daten \rightarrow Priori spielt keine Rolle
- > oder: es gibt Regelpriori \rightarrow Laplace

$\tilde{\Phi}: A_1 \rightarrow \mathbb{R}$, $a \mapsto \sum_{j=1}^m u(a, v_j)$ oder $\tilde{\Phi}: A_1 \rightarrow \mathbb{R}$, $a \mapsto \frac{1}{m} \sum_{j=1}^m u(a, v_j)$ als Kriteriumsfkt.
 ↳ alle Umweltzustände gleich gewichtet \cong Bayes-Regel mit gleichverteilter Priori

Rechtfertigung durch „Prinzip vom unzureichenden Grund“:

Wenn nichts dafür spricht, dass eines der Elementareignisse wahrscheinlicher ist als die anderen, dann sind sie gleichwahrscheinlich.

(Verallgemeinerung auf unendliches \otimes) \rightarrow nichtinformative Priori-Vtlg.

z.B. Gleichvlg., Jeffrey-Regel, Jaynes-Regel, Übergang zu Credalmengen)

HURWICZ-KRITERIUM

Minimax zu pessimistisch

↪ Einführung eines Optimismusparameters

ERFAHRUNGSKRITERIUM von Hodges und Lehmann

Kompromiss zwischen Bayes & Minimax

Hurwicz-Kriterium

$\bar{\Phi}: A_1 \rightarrow \mathbb{R}$, $a \mapsto \bar{\Phi}(a)$

Minimax-Kriterium

$$\bar{\Phi}(a) = \alpha \max_j u(a, v_j) + (1-\alpha) \min_j u(a, v_j)$$

Optimismusparameter

Erfahrungskriterium

benutzen Wlt. der wir nicht trauen

$\Phi: A_1 \rightarrow \mathbb{R}$, $a \mapsto \Phi(a)$



$$\Phi(a) = \mu \cdot \underbrace{\left(\sum_{j=1}^m u(a, v_j) \pi(v_j) \right)}_{\text{Vertrauensparam.}} + (1-\mu) \cdot \underbrace{\left(\min_j u(a, v_j) \right)}_{\text{Minimax-Kriterium}}$$

→ Gewichtung durch μ
 (wie bestimme ich μ ?)

→ Gewichtung des max und min durch α
 (wie bestimme ich α ?)

Minimax-Regret Regel Nielsens-Savage-Regel

Minimax zu pessimistisch

↳ beachtet auch den Abstand zum Möglichen

Regretfunktion

$$r: A \times \Theta \rightarrow \mathbb{R}, (a_i, \theta_j) \mapsto r(a_i, \theta_j)$$

$$r(a_i, \theta_j) = \max_{\ell=1, \dots, n} (u(a_\ell, \theta_j)) - u(a_i, \theta_j) \text{ bzw. } l(a_i, \theta_j) - \min_{\ell=1, \dots, n} (l(a_\ell, \theta_j))$$

Max. jedes ℓ minus der jeweilige Nutzen

→ Entscheidungsproblem heißt **induziertes Regret Problem**

Minimax-Regret Aktion a^*

$$\max_{j=1, \dots, m} r(a^*, \theta_j) \leq \max_{j=1, \dots, m} r(a_i, \theta_j) \quad \forall a_i \in A$$

größer Regret jeder Aktion

→ Minimum wählen

Bayes-Aktionen: im Bayes-Problem ist egal, ob die Nutzen- oder Regret-Tafel genutzt wird

Kritik:

- wie wahrsch. sind die Umweltzustände?
- optimale Aktion ändert sich bei Hinzufügen einer neuen suboptimalen unabhängigen Aktion

Bestimmung optimaler Aktionen

Konvexe Mengen

Eine Menge ist konvex, wenn beliebige Konvexitätskombinationen von Elementen der Menge selbst wieder in der Menge enthalten sind.

→ „Eine Menge ist konvex, wenn ich zwei beliebige Elemente der Menge nehmen kann und deren Verbindung ebenfalls in der Menge liegt.“

=> um Extremwerte zu finden müssen nur noch die Ränder angesehen werden

↳ Optimierung über endliche statt unendliche Menge

- die Menge aller Wirtschaftsmaße ist konvex → gemischte Erweiterungen sind konvex

- **Extrempunkte**: der Rand der konvexen Menge $E(M)$
↳ nicht über sie zu optimieren

lineare Optimierung

Zur Lösungsmenge linearer Programme:

- finde ich eine zulässige Lösung, dann weiß ich, es gibt ein Optimum
- habe ich 2 versch. Optimallösungen ist auch die Verbindung Optimalsg.

Berechnung von Optimallösungen:

- Problem: Anzahl der Extrempkt. wächst mit steigender Anzahl der Variablen exp. an
- Simplex-Verfahren: sucht in geschickter Weise die Extrempunkte ab
- innere-Punkte-Methoden
- 2-3 Variablen: graphische Lösung

Standard-Minimum Problem (Primal)

Zielfunktion
 gegeben (z.B. Kosten) $\rightarrow \underbrace{C^T \cdot w}_{(1 \times n) \cdot (n \times 1)} \rightarrow \min_w$

unter den Nebenbedingungen

$$R \cdot w \geq b \quad \text{konvexes Polyeder (z.B. AI)}$$

$$w \geq 0 \quad \text{Nichtnegativität}$$

$$\rightarrow \text{erfüllt } + c^T \cdot \bar{w} > -\infty \Rightarrow \text{zulässig}$$

lassen
 sich in
 einander
 umformen

Standard-Maximum Problem (Primal)

Zielfunktion
 gegeben (z.B. Kosten) $\rightarrow \underbrace{C^T \cdot w}_{(1 \times n) \cdot (n \times 1)} \rightarrow \max_w$

unter den Nebenbedingungen

$$R \cdot w \leq b \quad \text{konvexes Polyeder (z.B. AI)}$$

$$w \geq 0 \quad \text{Nichtnegativität}$$

$$\rightarrow \text{erfüllt } + c^T \cdot \bar{w} < \infty \Rightarrow \text{zulässig}$$

Duales standard-Max Problem

$$b^T \cdot u \rightarrow \max_u$$

$$\text{Nebenbed.: } R^T \cdot u \leq c, \quad u \geq 0$$

Duales Programm

manchmal einfacher zu lösen

Optimallsg.
 werden als Schatten-
 preise/Opportunitäts-
 kosten bezeichnet

Duales standard-Min Problem

$$b^T \cdot u \rightarrow \min_u$$

$$\text{Nebenbed.: } R^T \cdot u \geq c, \quad u \geq 0$$

$$c^T \cdot w \rightarrow \min_w \quad \text{bleibt gleich}$$

$$\text{Nebenbed.: } [R, -I_m] \cdot \begin{bmatrix} w \\ w_s \end{bmatrix} = b$$

echte Gleichheit
 schlußvar.

$$w \geq 0$$

$$w_s \geq 0$$

KANONISCHE FORM

alle Restriktionen liegen als
 Gleichungen vor
 (Schlußvariablen)

\rightarrow man kann erkennen, bei
 welchen Restriktionen noch
 "spiel ist".

$$c^T \cdot w \rightarrow \max_w$$

$$\text{Nebenbed.: } [R, I_m] \cdot \begin{bmatrix} w \\ w_s \end{bmatrix} = b$$

schlußvar.

$$w \geq 0$$

$$w_s \geq 0$$

DER SATZ VOM KOMPLEMENTÄREN SCHLUß

dsg. Primalprob. in kanonischer Form: $(\tilde{w}^T, \tilde{w}_s^T)^T$

dsg. duales Prob. in kanonischer Form: $(\tilde{u}^T, \tilde{u}_r^T)^T$

sind genau dann optimal, wenn $\tilde{w}^T \cdot \tilde{u}_r + \tilde{w}_s^T \cdot \tilde{u} = 0$

"Für kein Paar von Optimallsg. für Primal- & Dual- Problem können Haupt- und zugehörige Schlußvariable beide echt positiv sein."

BAYES-KRITERIUM

$$(e_1, \dots, e_n) \cdot \begin{pmatrix} \lambda_1 \\ \vdots \\ \lambda_n \end{pmatrix} \rightarrow \max_{\lambda_1, \dots, \lambda_n}$$

Anzahl Aktionen
 $\hookrightarrow := E_\pi(u(a_i))$
 ↳ rand. Aktionen
 ↳ brauchen wir, damit lin. OP

Nebenbed.:

$$\left. \begin{array}{l} \lambda_1, \dots, \lambda_n \geq 0 \\ \sum_{i=1}^n \lambda_i = 1 \end{array} \right\} \Rightarrow \text{liegen im Einheitssimplex}$$

Beobachtung:

Ecken des Einheitssimplex entsprechen den Punktmassen in der gemischten Erweiterung (den reinen Aktionen)
 → Optimum wird in reiner Aktion angenommen

$$(\phi_\pi(\lambda) - E_\pi(u(\lambda))) = \sum_{i=1}^n E_\pi(u(a_i)) \lambda(a_i)$$

Maximin-Kriterium

↓ damit alle Variablen ≥ 0 sind

$$M_1 - M_2 \rightarrow \max_{M_1, M_2, \lambda(a_1), \dots, \lambda(a_n)}$$

Nebenbed.:

- $\lambda(a_1), \dots, \lambda(a_n), M_1, M_2 \geq 0$
- $\sum_{i=1}^n u(a_i, v_j) \lambda(a_i) \geq M_1 - M_2 \quad \forall j = 1, \dots, m$
- $\sum_{i=1}^n \lambda(a_i) = 1$

$$\left(\begin{array}{l} \Phi_M(\lambda) = \min_j \tilde{u}(\lambda, v_j) = \min_j (\sum_{i=1}^n u(a_i, v_j) \lambda(a_i)) \\ \rightarrow \text{nicht linear in Gewichten} \rightarrow \text{umformen} \\ \Phi_M(\lambda) = \max \{ M_1 - M_2 : M_1, M_2 \geq 0 \wedge M_1 - M_2 \leq \tilde{u}(\lambda, v_j) \forall j \} \end{array} \right)$$

Beobachtung:

Zulässige Menge \neq Einheitssimplex
 → Randomisieren kann sich lohnen

Hodges & Lehmann-Kriterium

→ unterscheidet sich zu Maximin lediglich in der Zielfkt.

Vertrauenskriterium

$$((1-\mu), (\mu-1), \mu e_1, \dots, \mu e_n) \cdot \begin{pmatrix} M_1 \\ M_2 \\ \lambda_1 \\ \vdots \\ \lambda_n \end{pmatrix} \rightarrow \max_{M_1, M_2, \lambda(a_1), \dots, \lambda(a_n)}$$

Nebenbed.:

- $\lambda(a_1), \dots, \lambda(a_n), M_1, M_2 \geq 0$
- $\sum_{i=1}^n u(a_i, v_j) \lambda(a_i) \geq M_1 - M_2 \quad \forall j = 1, \dots, m$
- $\sum_{i=1}^n \lambda(a_i) = 1$

$$\left(\Phi_M(\lambda) = \mu E_{\pi}(\tilde{u}(\lambda)) + (1-\mu) \min_j \tilde{u}(\lambda, v_j) \right)$$

→ Umformung des Maximin-Teils

Beobachtung:

Auch hier kann sich Randomisieren lohnen

VERALLGEMEINERTER WAHRSCHEINLICHKEITSBEGRIFF

Typ I / I'

← Kontinuum an Mischtypen →

Typ II / II'

Bernoulli / Bayes

Modellierung z.B. via Vertrauenskriterium

Maximin

- klassische Wlt: Jede Mengenfkt. $p(\cdot)$, die die Axiome von Kolmogorov erfüllt.

→ wir suchen eine andere Art Unsicherheiten zu modellieren

↪ statt einer Priori nehmen wir alle Prioris, die mit unseren „constraints“ (unserem Wissen) kompatibel sind

⇒ ZIEL: Verallgemeinerte Wlsrechnung

↪ Berücksichtigung des Ausmaßes an Ambiguität

↪ Zuverlässigkeit statt (Über-)präzision

reliable statt präzisen Schlüssen

Credalmengen

- Credalmenge M : die Menge in ihrer Gesamtheit beschreibt die Wlt., kein Element ist wahrscheinlicher als ein anderes
- Größe der Menge reflektiert Ausmaß der Ambiguität
- klassische Wlt. als Spezialfall: Ein-Punkt-Menge

INTERVALLWAHRSCHEINLICHKEIT

- statt $p: A \rightarrow \mathbb{R}$, $A \mapsto p(A)$ betrachtet man
 $\text{Menge aller abgeschlossenen Intervalle in } [0;1]$ \swarrow \searrow
 Kapazität
 $P: A \rightarrow \mathbb{Z}_+([0;1]), A \mapsto P(A) = [\underline{L}(A), \overline{U}(A)]$
 lower upper
- klassische Wkt. als Spezialfall: $L(\cdot) = U(\cdot)$

AUFPASSUNGEN DER MENGE

- epistemische Sicht: es gibt wahre Wkt. \rightarrow unbekannt
 \hookrightarrow Menge / Intervall betrachten
- ontologische Sicht: Wkt. grundsätzlich als intervall-/mengenwertige Entität

ELLBERG - EXPERIMENT

- aus Urne wird eine Kugel gezogen
- Anteil rot ist $\frac{1}{3}$, Anteil gelb & schwarz unbekannt
- Situation 1: wähle
 - $a_1: 100 \$$, falls rot
 - $a_2: 100 \$$, falls schwarz \hookrightarrow mehr deute wählen a_1
- Situation 2: wähle
 - $a_3: 100 \$$, falls rot oder gelb
 - $a_4: 100 \$$, falls schwarz oder gelb \hookrightarrow mehr deute wählen a_4
- \Rightarrow es kann keine Priori geben, bei der man so entscheiden würde
 \rightarrow die Entscheidungsfindung wird noch von etwas anderem beeinflusst \rightarrow Ambiguity

- R-Wkt.: $M \neq \emptyset \Rightarrow P(\cdot)$ heißt R-Wkt & M heißt Struktur

Struktur/Menge M ist nicht leer / Intervallgrenzen werden nicht von Strukturelementen angenommen $\rightarrow L(\cdot)$ und $U(\cdot)$ können „zu weit“ sein
 \hookrightarrow Überprüfung: lineare Optimierung

- F-Wkt.: $\forall A \in M \quad L(A) = \inf_{p \in M} p(A)$ und $U(A) = \sup_{p \in M} p(A)$ (\Rightarrow R-Wkt.)
 Intervallgrenzen und Struktur passen zusammen \rightarrow Keine der Intervallgrenzen ist zu weit
 \hookrightarrow Überprüfung: lineare Optimierung Extremalpunktmenge
 \rightarrow Struktur ist konkaves Polyeder $\rightarrow E(M)$ nicht leer & endlich

VERALLGEMEINERTE ERWARTUNGSWERTE

INTERVALLWERTIGER ERWARTUNGSWERT

wir rechnen alle E aus und nehmen
 \min & \max

M -int + nicht negativ

$$\begin{aligned} E_M X &:= [\underline{E}_M X; \overline{E}_M X] \\ &:= [\inf_{p \in M} E_p X; \sup_{p \in M} E_p X] \end{aligned}$$

- Choquet-Integrale
 $\int X dL := \int L(\{x \mid x > z\}) dx$
 $\int X dU := \int U(\{x \mid x < z\}) dx$

\hookrightarrow Allgemein gilt: $\int X dL \leq \underline{E}_M X \leq \overline{E}_M X \leq \int X dU$

VERALLGEMEINERTER ERWARTUNGSNUTZEN

statt einer Zahl nun Intervalle

\rightarrow wie ordnen?

- Repräsentationen: Intervalle durch eine reelle Zahl beschreiben (Mittelpunkt, untere Intervallgrenze...)
- Aussagen analog zur Zulässigkeit (E-Zulässigkeit,...)
 \hookrightarrow keine vollständige Ordnung

X heißt M -integrierbar, wenn X für jedes $p \in M$ p -integrierbar ist.

$$E_M(u(a)) = [\inf_{\pi \in M} E_\pi(u(a)); \sup_{\pi \in M} E_\pi(u(a))]$$

Priori
verallgemeinerte Priori-Bewertung

Entscheidungskriterien

- Max-E-Min-Kriterium $\Phi(\cdot, \mathcal{U}): A \rightarrow \mathbb{R}, a \mapsto \underline{\mathbb{E}}_{\mathcal{U}}(u(a))$ wir wählen unteren Erwartungswert
→ „lokales Maximin-Kriterium“
- Max-E-Min-Aktion $a^* \in A$ mit $\Phi(a^*, \mathcal{U}) \geq \Phi(a, \mathcal{U}) \forall a \in A$ wir wählen Aktion mit dem größten unteren Erwartungswert unter allen Zuständen
nicht zwingend gleicher Zustand
also mit $\underline{\mathbb{E}}_{\mathcal{U}}(u(a^*)) \geq \underline{\mathbb{E}}_{\mathcal{U}}(u(a)) \forall a \in A$
- ↳ völlige Ambiguität: \cong Maximin-Kriterium
- ↳ perfekte probabilistische Information: \cong Bayes-Kriterium
- lineare Repräsentation mit der Vorsicht η $\Phi_{\eta}(\mathcal{U}): A \rightarrow \mathbb{R}, a \mapsto \eta \cdot \underline{\mathbb{E}}_{\mathcal{U}}(u(a)) + (1-\eta) \bar{\mathbb{E}}_{\mathcal{U}}(u(a))$ Linearkomb. der \mathbb{E}
→ „lokales Hurwicz-Kriterium“
- optimale Aktion bei der Vorsicht η $a^*\eta$ mit $\Phi_{\eta}(a^*\eta, \mathcal{U}) \geq \Phi_{\eta}(a, \mathcal{U}) \forall a \in A$
- ↳ $\eta = 1 \Rightarrow$ Max-E-Min-Prinzip
- E -zulässig / E -admissible:
Eine Aktion $a_{\pi} \in A$ heißt E -zulässig bzgl. der verallgemeinerten Priori-Bewertung $\Pi(\cdot)$ bzw. \mathcal{U} , falls es ein $\Pi(\cdot) \in \mathcal{U}$ gibt, so dass a_{π} Bayes-Aktion zu $\Pi(\cdot)$ ist.
- $\mathcal{U} = \{\Pi\}$ (ideale Stochastizität): a^* ist genau dann optimal, wenn a^* Bayes-Aktion zu $\Pi(\cdot)$ ist
- $\mathcal{U} = \{\text{alle klassischen Wkt.}\}$ (Unsicherheit): a^* ist genau dann
 - Max-E-Min Aktion, wenn a^* Maximin-Aktion ist
 - optimale Aktion mit Vorsicht η , wenn a^* Hurwicz-Aktion zum Optimismusparameter $(1-\eta)$ ist

E_{ϵ} -Admissibilität

a^* heißt E_{ϵ} -admissibel, falls es eine Familie $(\Pi_a)_{a \in A}$ von Wkt. in \mathcal{U} gibt, so dass gilt:

- $\underline{\mathbb{E}}_{\Pi_a}(u(a^*)) \geq \underline{\mathbb{E}}_{\Pi_a}(u(a)) \forall a \in A$
- $\|\Pi_a - \Pi_{a'}\|_1 \leq \epsilon \quad \forall a, a' \in A$

Kompromiss zwischen E -Admissibilität und Maximalität

Maximalität

a^* heißt \mathcal{U} -maximal, falls $\forall a \in A \exists \Pi_a \in \mathcal{U}: \underline{\mathbb{E}}_{\Pi_a}(u(a^*)) \geq \underline{\mathbb{E}}_{\Pi_a}(u(a))$

Abschwächung der E -Admissibilität
→ Max lokal statt global

Lineare Optimierung

irgendeine Zufallsvar.
 $\mathcal{U} = \{\Pi: \underline{b}_s \leq \mathbb{E}_{\Pi}(f_s) \leq \bar{b}_s \forall s=1, \dots, r\}$
wobei

- $\underline{b}_s \leq \bar{b}_s \in \mathbb{R} \quad \forall s=1, \dots, r$
- $f_s: \Theta \rightarrow \mathbb{R} \quad \forall s=1, \dots, r$

$$\begin{pmatrix} 1 & \dots & 1 \\ -1 & \dots & -1 \\ f_{s1} & \dots & f_{sm} \\ -f_{s1} & \dots & -f_{sm} \\ \vdots & & \vdots \\ f_{r1} & \dots & f_{rm} \\ -f_{r1} & \dots & -f_{rm} \end{pmatrix} \cdot \begin{pmatrix} \Pi_1 \\ \vdots \\ \Pi_m \end{pmatrix} \leq \begin{pmatrix} 1 \\ -1 \\ \vdots \\ \bar{b}_1 \\ \bar{b}_1 \\ \vdots \\ \bar{b}_r \\ \bar{b}_r \end{pmatrix}$$

E-ADMISSIBILITÄT

Vorüberlegungen:

- es reicht aus, sich auf keine Aktionen zu beschränken
- für eine seine Aktion muss überprüft werden, ob sie für ein Maß aus unserer Credalmenge M Bayes-optimal ist

Idee: Maximiere über die Summe der Gewichte der (potentiellen) priori π , unter den Nebenbedingungen

$$\pi \in M$$

- a max den Erwartungsnutzen bzgl. π unter allen Aktionen

Aktion a ist dann E-zulässig, falls das Maximum 1 ist.

Die Aktion $a_i \in A$ ist genau dann E-admissible bzgl. der Credalmenge M , falls der Optimalwert des folgenden linearen Programms genau 1 ist.

$$(1, \dots, 1) \cdot \begin{pmatrix} \pi_1 \\ \vdots \\ \pi_m \end{pmatrix} \rightarrow \max_{\pi}$$

unter den Nebenbedingungen:

$$-(\pi_1, \dots, \pi_m) \geq 0$$

$$-\sum_{j=1}^m \pi_j \leq 1$$

die Komp. von π dürfen sich höchst. zu 1 addieren (sonst kein Standardmaxproblem)

$$-b_s \leq \sum_{j=1}^m f_s(\pi_j) \cdot \pi_j \leq \bar{b}_s \quad \forall s=1, \dots, r$$

π muss in der Credalmenge liegen

$$-\sum_{j=1}^m (u_{pj} - u_{ij}) \cdot \pi_j \leq 0 \quad \forall p=1, \dots, n$$

a_i muss unter allen seinen Aktion E bzgl. π max

$$\text{d.h.: } E_{\pi}(a_p) \leq E_{\pi}(a_i) \quad \forall p=1, \dots, n$$

VERÄLIGEMEINERTER ERWARTUNGSNUTZEN

Unterer Erwartungsnutzen

$E_M(u(a_i))$ der Aktion $a_i \in A$ ergibt sich als Optimalwert des folgenden Linearen Programms.

$$u(a_i; \pi_1) \downarrow (u_{i1}, \dots, u_{im}) \cdot \begin{pmatrix} \pi_1 \\ \vdots \\ \pi_m \end{pmatrix} \rightarrow \min_{\pi}$$

unter den Nebenbedingungen:

$$-(\pi_1, \dots, \pi_m) \geq 0$$

$\left. \begin{array}{l} \pi \text{ ist Wktsmaß} \\ \sum_{j=1}^m \pi_j = 1 \end{array} \right\} \pi \text{ in Credalmenge}$

$$-\sum_{j=1}^m f_s(\pi_j) \cdot \pi_j \leq \bar{b}_s \quad \forall s=1, \dots, r$$

$\left. \begin{array}{l} \pi \text{ hält E-Constraints ein} \\ \dots \end{array} \right\} \pi \text{ in Credalmenge}$

Oberer Erwartungsnutzen

$\bar{E}_M(u(a_i))$ der Aktion $a_i \in A$ ergibt sich als Optimalwert des folgenden Linearen Programms.

$$u(a_i; \pi_1) \downarrow (u_{i1}, \dots, u_{im}) \cdot \begin{pmatrix} \pi_1 \\ \vdots \\ \pi_m \end{pmatrix} \rightarrow \max_{\pi}$$

unter den Nebenbedingungen:

$$-(\pi_1, \dots, \pi_m) \geq 0$$

$\left. \begin{array}{l} \pi \text{ ist Wktsmaß} \\ \sum_{j=1}^m \pi_j = 1 \end{array} \right\} \pi \text{ in Credalmenge}$

$$-\sum_{j=1}^m f_s(\pi_j) \cdot \pi_j \leq \bar{b}_s \quad \forall s=1, \dots, r$$

$\left. \begin{array}{l} \pi \text{ hält E-Constraints ein} \\ \dots \end{array} \right\} \pi \text{ in Credalmenge}$

Abhandlung für randomisierte Aktionen

$E_M(\tilde{u}(A))$ bzw. $\bar{E}_M(\tilde{u}(A))$ der randomisierten Aktion $A \in M(A)$ lässt sich als Optimalwert des folgenden linearen Programms darstellen.

$$\underbrace{\tilde{u}(A, \pi_A)}_{\downarrow} \cdot (\tilde{u}_{A,1}, \dots, \tilde{u}_{A,m}) \cdot \begin{pmatrix} \pi_1 \\ \vdots \\ \pi_m \end{pmatrix} \rightarrow \min_{\pi} \text{ bzw. } \max_{\pi}$$

unter den selben Nebenbedingungen

→ Problem: müssen nicht nur 1, sondern ∞ viele lin. Programme lösen

Max-Min Kriterium

Vorüberlegung: randomisieren kann sich lohnen

- Variante 1: $\underset{\substack{\text{Extrempunkte} \\ \downarrow}}{E(M)} = \{ \pi^{(1)}, \dots, \pi^{(n)} \}$ bekannt
Die rand. Aktion $\tilde{A}^* = (\lambda_{ca_1}, \dots, \lambda_{ca_n})$ ist genau dann Max-Min Lösung, wenn sie Optimallösung des folgenden linearen Programms ist.

$$M_1 - M_2 \rightarrow \max_{M_1, M_2, \lambda_{ca_1}, \dots, \lambda_{ca_n}}$$

unter den Nebenbedingungen:

$$-(M_1, M_2, \lambda_{ca_1}, \dots, \lambda_{ca_n}) \geq 0$$

$$\sum_{i=1}^n \lambda_{ca_i} = 1 \quad \underset{\substack{\text{Extrempunkt} \\ \downarrow}}{E_{\pi^{(p)}}(u_{ca_i})}$$

$$M_1 - M_2 \leq \sum_{i=1}^n e_{ip} \lambda_{ca_i} \quad \forall p \in \{1, \dots, k\}$$

- Variante 2: Extrempunkte nicht bekannt
Die rand. Aktion $\tilde{A}^* = (\lambda_{ca_1}, \dots, \lambda_{ca_n})$ ist genau dann Max-Min Lösung, wenn sie Optimallösung des folgenden linearen Programms ist.

$$M_1 - M_2 + \sum_{s=1}^r (b_s x_s - \bar{b}_s y_s) \rightarrow \max_{M_1, M_2, x_1, \dots, x_r, y_1, \dots, y_s, \lambda_{ca_1}, \dots, \lambda_{ca_n}}$$

unter den Nebenbedingungen:

$$-(M_1, M_2, x_1, \dots, x_r, y_1, \dots, y_s, \lambda_{ca_1}, \dots, \lambda_{ca_n}) \geq 0$$

$$-\sum_{i=1}^n \lambda_{ca_i} = 1$$

$$-M_1 + M_2 + \sum_{s=1}^r f_s(x_j)(x_s - y_s)$$

$$\leq \sum_{i=1}^n u_{ij} \lambda_{ca_i} \quad \forall j \in \{1, \dots, m\}$$

⇒ beide Varianten führen zum gleichen Ergebnis

- Variante 1 erfordert Preprocessing (Berechnung der Extrempunkte)
 - aber: auch für Variante 2 müssen gewisse Extrempunkte ausgerechnet werden
- liegen geschlossene Formeln zur Berechnung vor: Variante 1
- müssen die Extrempkt. ebenfalls über Optimierung bestimmt werden: hängt von Komplexität der Credalmenge ab

Nutzentheorie

- intrinsischer Nutzen:

- Nutzen ist eine Eigenschaft eines Objekts
- unabhängig von anderen Objekten und unabhängig vom „agent“

- relationaler Nutzen:

- Nutzen eines Objekts für einen spezifischen Agenten
- kann nur indirekt im Vergleich mit anderen vergleichbaren Objekten beobachtet werden

↳ Nutzenbegriff der Vorlesung

ORDINALE NUTZEN-THEORIE

Relationen

Eigenschaften binärer Relationen

A ist nicht-leere Menge, $R \subseteq A \times A$ ist eine binäre Relation auf A .

Dann ist R :

- reflexiv $\Leftrightarrow (a, a) \in R \quad \forall a \in A$
- symmetrisch $\Leftrightarrow (a, b) \in R \Rightarrow (b, a) \in R \quad \forall a, b \in A$
- transitiv $\Leftrightarrow (a, b), (b, c) \in R \Rightarrow (a, c) \in R \quad \forall a, b, c \in A$
- negativ transitiv $\Leftrightarrow (a, b) \notin R \wedge (b, c) \notin R \Rightarrow (a, c) \notin R \quad \forall a, b, c \in A$
- asymmetrisch $\Leftrightarrow (a, b) \in R \Rightarrow (b, a) \notin R \quad \forall a, b \in A$
- antisymmetrisch $\Leftrightarrow (a, b), (b, a) \in R \Rightarrow a = b \quad \forall a, b \in A$
- kompletts $\Leftrightarrow (a, b) \in R \vee (b, a) \in R \quad \forall a, b \in A$
 \hookrightarrow oder auch vollständig

Arten von binären Relationen

A ist nicht-leere Menge. Eine binäre Relation auf A ist:

- eine Präferenz
 \Leftrightarrow kompletts + transitiv
- eine strikte Präferenz
 \Leftrightarrow asymmetrisch + negativ transitiv
- eine lineare Ordnung (ist immer auch Präferenz)
 \Leftrightarrow kompletts + transitiv + antisymmetrisch
- eine Äquivalenz-Relation
 \Leftrightarrow reflexiv + symmetrisch + transitiv

Jede Präferenz kann in 2 disjunkte Teile unterteilt werden:

A nicht-leere Menge, \succsim Präferenz-Relation auf A

$$(a, b) \in R : aRb$$

$$(a, b) \notin R : \neg aRb$$

Strikter Teil: $\succ \subseteq A \times A$

Indifferenter Teil: $\sim \subseteq A \times A$

$$\forall a, b \in A : a \succ b \Leftrightarrow a \succsim b \wedge \neg b \succsim a$$

$$\forall a, b \in A : a \sim b \Leftrightarrow a \succsim b \wedge b \succsim a$$

Eigenschaften von Präferenz-Relationen

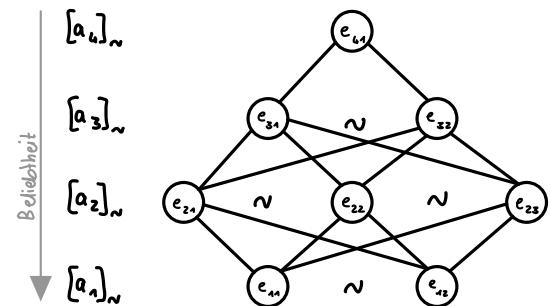
A ist nicht-leere Menge, \succsim ist Präferenz-Relation auf A .

Es gelten die folgenden Eigenschaften:

- \sim ist eine Äquivalenz-Relation auf A
- \succ ist eine strikte Präferenz auf A
- $\forall a, b, c \in A : (a \succsim b \wedge b \succsim c) \Rightarrow a \succsim c$
- $\forall a, b, c \in A : (a \succsim b \wedge b \succsim c) \Rightarrow a \succ c$
- $\forall a, b \in A : a \succsim b \vee b \succsim a \vee a \sim b$

lin. Ordnung

Präferenz-Relation



Quotient einer Präferenz-Relation

- $[a]_\sim := \{b \in A : a \sim b\}$ alle zu a äquivalenten Elemente
- Quotienten-Menge $A_\sim := \{[a]_\sim : a \in A\}$ Menge von Mengen

Lineare Ordnung

Die binäre Relation $[\succsim]$ auf A_\sim ist eine lin. Ordnung:
 $\forall [a]_\sim, [b]_\sim \in A_\sim : [a]_\sim [\succsim] [b]_\sim \Leftrightarrow (\exists a_1 \in [a]_\sim, b_1 \in [b]_\sim : a_1 \succsim b_1)$

Repräsentation

\rightarrow soll später die Nutzenfkt. werden

Lass A eine nicht-leere Menge und R eine binäre Relation auf A sein.

R wird repräsentierbar in (\mathbb{R}, \geq) genannt $\Leftrightarrow \exists \phi : A \rightarrow \mathbb{R} : \forall a, b \in A : aRb \Leftrightarrow \phi(a) \geq \phi(b)$

\hookrightarrow Funktion heißt reelle Repräsentation des Paares (A, R)

- statt der Relation kann ich mir auch die Funktionswerte der Repräsentation anschauen
- wenn es diese Repräsentation gibt folgt daraus Vollständigkeit und Transitivität

- Repräsentation einer linearen Ordnung

Lass A eine nicht-leere Menge und \succsim eine lineare Ordnung auf A sein.

\succsim ist repräsentierbar in $(\mathbb{R}, \geq) \Leftrightarrow \exists \phi: A \rightarrow \mathbb{R}: \forall a, b \in A: a \succsim b \Rightarrow \phi(a) \geq \phi(b)$

- Cantor's Theorem

Lass A eine nicht-leere Menge und \succsim eine lineare Ordnung auf A sein.

A ist abzählbar
(nicht mächtiger als die reellen Zahlen) $\Rightarrow \succsim$ ist repräsentierbar in (\mathbb{R}, \geq)
suffizient, aber nicht nötig

A ist nicht-leere Menge, $\succsim \subset A \times A$ ist reflexiv + transitiv: (muss nicht lin. Ordn.)

- $B \subset A$ heißt **ordnungsdicht** bzgl \succsim
 $\Leftrightarrow \forall a, c \in A, a > c : \exists b \in B: a \succsim b \succsim c$

- (A, \succsim) heißt **ordnungsseparabel**
 $\Leftrightarrow \exists B \subset A$ ^{ordnungsdicht}: B ist abzählbar

- Birkhoff's Theorem

Verallgemeinerung von Cantor's Theorem

Lass A eine nicht-leere Menge und \succsim eine lineare Ordnung sein.

\succsim ist repräsentierbar in $(\mathbb{R}, \geq) \Leftrightarrow (A, \succsim)$ ist ordnungsseparabel

- Repräsentation einer Präferenz-Relation

Lass A eine nicht-leere Menge und \succsim eine Präferenz auf A sein.

\succsim ist repräsentierbar in $(\mathbb{R}, \geq) \Leftrightarrow (A, \succsim)$ ist ordnungsseparabel

folgt

- Eindeutigkeit der Repräsentation

- nur bis auf streng monoton wachsende Transformationen eindeutig
 \Rightarrow Abstände von Werten haben keine Bedeutung
 \hookrightarrow Nutzendifferenzen anschauen ergibt keinen Sinn

ORDINATER NUTZEN IN DER ENTSCHEIDUNGSTHEORIE

- (A, \succsim) ist Präferenz, die in (\mathbb{R}, \geq) repräsentierbar ist
- $\Theta := \{v_1, \dots, v_m\}$ ist endliche Menge der Umweltzustände
- $A^I := \{x_1, \dots, x_n\} \subset A^\Theta$ ist endliche Menge der Aktionen
 \hookrightarrow Zufallsvar. die jedem v_i ein Element aus A zuordnet
- $C := \{c_{ij} := x_i(v_j)\}_{i \in \underline{n}, j \in \underline{m}}$ ist Menge der relevanten Konsequenzenraum Konsequenzen
- $\succsim_C := C^2 \cap \succsim$ ist die Präferenzrelation auf C eingeschränkt

\Rightarrow Ziel: (Präferenz-) Relation auf A^I

Es ist möglich Dominanz & Maximin-Kriterium ohne Nutzenfkt. zu definieren:

schwache Dominanz

$$x_1, x_2 \in A^I : x_1 \geq_{\text{dom}} x_2 : \Leftrightarrow \\ (\forall \theta \in \Theta : x_1(\theta) \succsim_C x_2(\theta))$$

Dominanz

$$x_1, x_2 \in A^I : x_1 >_{\text{dom}} x_2 : \Leftrightarrow \\ (\forall \theta \in \Theta : x_1(\theta) \succsim_C x_2(\theta)) \wedge \\ (\exists \theta_0 \in \Theta : x_1(\theta_0) >_C x_2(\theta_0))$$

Maximin

$$x_1, x_2 \in A^I : x_1 \succsim_{\min} x_2 : \Leftrightarrow \\ x_1(v_{x_1}) \succsim_C x_2(v_{x_2}) \quad \text{mit} \\ v_z \in \{v^*\} : \forall \theta \in \Theta : z(\theta) \succsim_C z(v^*) \quad \text{für } z \in \{x_1, x_2\}$$

- Erwartungswertbildung ist nicht möglich (Stärke der Präferenz nicht bekannt)

\hookrightarrow Bayes-Kriterium nicht anwendbar

\rightarrow probabilistische Informationen können nicht verwendet werden

KARDINALE NUTZEN

LÖTTERIEN

- Einfache Lötterien

Wahlfkt. die endlich vielen Elementen pos. Werte zuweist (ähnlich wie gemischte Erweiterung)

→ es ist möglich die Stärke der Präferenzen zu implizieren

Lass A eine nicht-leere Menge von Alternativen sein. Für $f: A \rightarrow \mathbb{R}$ mit $B \subset \mathbb{R}$ nennen wir $\text{supp}(f) := \{a \in A : f(a) > 0\}$ den Support von f . Die Funktion $p: A \rightarrow [0, 1]$ mit $|\text{supp}(p)| < \infty$ und $\sum_{a \in \text{supp}(p)} p(a) = 1$ ist eine einfache Lottotierung auf A . Die Menge aller einfachen Lötterien auf A wird als \mathcal{L}_A bezeichnet.

Beispiel: $A = \{\text{Tee, Wasser, Bier}\}$

einfache Lötterien sind z.B.: $(1, 0, 0), (0, 1, 0)$, $\underbrace{(0, 1, 0.5, 0.4)}_{\substack{\text{summe ist 1} \\ \hookrightarrow \text{sicher Tee} \hookrightarrow \text{sicher Bier} \hookrightarrow 10\% \text{ Tee}, 50\% \text{ Wasser}, 40\% \text{ Bier}}}$

- Zusammengesetzte Lötterien

2 hintereinander geschaltete Lötterien → einfache Lottotierung

Für $p, q \in \mathcal{L}_A$ und $\alpha \in [0, 1]$ definiere die zusammengesetzte Lottotierung $pq_\alpha := \alpha p + (1-\alpha)q$ komponentenweise.

→ pq_α ist wieder eine einfache Lottotierung in \mathcal{L}_A

VON NEUMANN-MORGENSTERN

- von Neumann-Morgenstern Axiome

Lass A eine nicht-leere Menge, \mathcal{L}_A die Menge der einfachen Lötterien auf A und \succsim eine binäre Relation auf \mathcal{L}_A sein.

1) Präferenzrelation

\succsim ist eine Präferenz-Relation auf \mathcal{L}_A (komplett + transitiv)

2) Unabhängigkeit → wie Dominanz

$\forall p, q, r \in \mathcal{L}_A, \alpha \in [0, 1] : p \succ q \Rightarrow \alpha p + (1-\alpha)r \succ \alpha q + (1-\alpha)r$ Wenn ich p besser als q finde, finde ich auch $p \succ r$ besser als $q \succ r$

3) Stetigkeit → Präferenzen sollen nah genug aneinander liegen

$\forall p, q, r \in \mathcal{L}_A : p \succ q \succ r \Rightarrow \exists \alpha, \beta \in (0, 1) : \alpha p + (1-\alpha)r \succ q \succ \beta p + (1-\beta)r$ ich kann zum besten mit kleiner Wkt. das schlechteste dazu addieren und es bleibt trotzdem besser als q

\hookrightarrow Es gibt kein zu guten / schlechten Lötterien

(nichts ist so schlecht, dass ich es nicht mit einer kleinen Wkt. in Kauf nehmen würde)

⇒ daraus folgt für alle $p, q, r \in \mathcal{L}_A$:

- $p \succ q \Rightarrow \forall \alpha, \beta \in [0, 1] : \alpha \geq \beta \Leftrightarrow \alpha p + (1-\alpha)p \succsim \beta p + (1-\beta)q$

Wenn die Wkt. auf dem besseren höher ist, finde ich das auch besser

- $p \sim q \Rightarrow \forall \alpha \in [0, 1] : \alpha p + (1-\alpha)r \sim \alpha q + (1-\alpha)r$

Wenn ich indifferent bin, bin ich auch mit hinzugefügtem r indifferent

- $p \succsim q \succsim r \wedge p \succ r \Rightarrow$ es existiert genau ein $\alpha^* \in [0, 1] : q \sim \alpha^* p + (1-\alpha^*)r$

$\hookrightarrow \alpha^*$ wird später genau der Flutswert der Nutzenfkt.

- von Neumann-Morgenstern Theorem

Lass A eine nicht-leere Menge und \succsim eine binäre Relation auf \mathcal{L}_A sein.

\succsim erfüllt die vNM Axiome $\Leftrightarrow \exists u: A \rightarrow \mathbb{R} : \forall p, q \in \mathcal{L}_A : p \succsim q \Leftrightarrow \sum_{a \in \text{supp}(p)} u(a) \cdot p(a) \geq \sum_{a \in \text{supp}(q)} u(a) \cdot q(a)$ Wenn $p \succsim q$ ist auch $E(p) \geq E(q)$

\hookrightarrow Diese Funktion u ist eindeutig bis auf positiven linearen Transformationen ($u^*: A \rightarrow \mathbb{R}, u^*(.) = c \cdot u(.) + d$)

⇒ eine Präferenzrelation, die die vNM Axiome erfüllt, ist darstellbar über E einer reellwertigen Nutzenfunktion.

Kardinaler Nutzen in der Entscheidungstheorie

- $\mathcal{C} := \{c_{ij} \mid i \in \underline{n}, j \in \underline{m}\}$ ist Konsequenzraum
 - \succsim binäre Relation auf \mathcal{C} , die die vNM Axiome erfüllt
 \Rightarrow wir können $u: \mathcal{C} \rightarrow \mathbb{R}$ wählen
 - π ist Wktmaß aus \mathcal{C}
 - \rightarrow Jedes Paar (x_i, π) ist eindeutig durch eine einfache Lotterie $p_{(i, \pi)}$ bestimmt:
- $$p_{(i, \pi)}(c) := \pi(x_i^{-1}(\{c\})) = \pi(\{j \in S : x_i(j) = c\})$$
- $$\Rightarrow p_{(i, \pi)} \succsim p_{(k, \pi)} \Leftrightarrow E_\pi(u \circ x_i) \geq E_\pi(u \circ x_k)$$
- $$\rightarrow x_i \text{ muss } x_k \text{ vorgezogen werden} \Leftrightarrow E_\pi(u(x_i)) > E_\pi(u(x_k))$$

\Rightarrow Das vNM Theorem akzeptiere ich sobald ich Erwartungsnutzen vergleiche / das Bayes-Kriterium nutze

Partiell kardinaler Nutzen

- Problem: Annahme der Kompletheit kann verletzt sein
 - \hookrightarrow Wir können nicht unbedingt ordnen, wenn z.B. die Konsequenzen unterschiedliche Dimensionen betreffen
- versch. Lösungsansätze:
 - Nicht-komplette ordinale Präferenzen: Wir können nicht mehr eine Nutzenfkt. finden, sondern eine Menge
 - Nicht-komplette kardinale Präferenzen: Nicht mehr ein vNM Erwartungswert, sondern eine Menge
 - Konsistente Präferenzsysteme: Präferenzen können sowohl ordinal als auch kardinal sein

Präferenzsysteme

- statt 1 Relation haben wir 2
 - Rangordnung zwischen den Konsequenzen
 - Rangordnung zwischen den Rangordnungen

Lass A eine Konsequenzmenge sein.

- $R_1 \subseteq A \times A$ ist reflexive + transitive Ordnung auf A
- $R_2 \subseteq R_1 \times R_1$ ist reflexive + transitive Ordnung auf R_1
- $\Rightarrow A = [A, R_1, R_2]$ heißt Präferenzsystem auf A

Repräsentation

- $A = [A, R_1, R_2]$ heißt konsistent $\Leftrightarrow \exists u: A \rightarrow [0, 1] : \forall a, b, c, d \in A :$
- $(a, b) \in R_1 \Rightarrow u(a) \geq u(b) \quad (u(a) = u(b) \Leftrightarrow (a, b) \in I_{R_1}^{\text{Indifferenz}})$
 - $((a, b), (c, d)) \in R_2 \Rightarrow u(a) - u(b) \geq u(c) - u(d)$
 $(u(a) - u(b) = u(c) - u(d)) \Leftrightarrow ((a, b), (c, d)) \in I_{R_2})$

Jede solche Funktion u heißt Repräsentation des Präferenzsystems A . Die Menge aller Repräsentationen u von A wird mit \mathcal{U}_A bezeichnet.

$\rightarrow \mathcal{U}_A \neq \emptyset \Leftrightarrow A$ ist konsistent

Beispiel: einfache Lotterien definieren

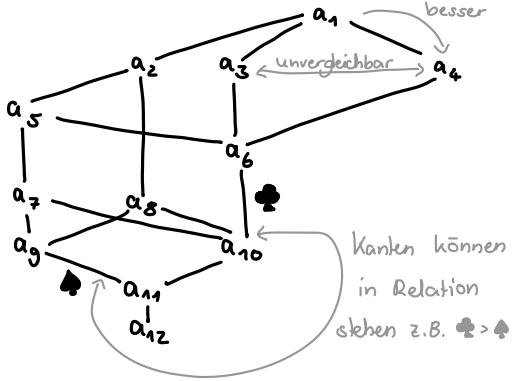
	v_1	v_2	v_3	v_4	$\mathcal{C} = \{c_1, \dots, c_{10}\}$
x_1	c_4	c_2	c_4	c_4	
\vdots					

$$p_{(1, \pi)}(c_1) = \pi(\{v_1, 3\}) ; p_{(1, \pi)}(c_2) = \pi(\{v_2, 3\})$$

$$p_{(1, \pi)}(c_3) = 0 ; p_{(1, \pi)}(c_4) = \pi(\{v_3, 3\}) + \pi(\{v_4, 4\})$$

$$p_{(1, \pi)}(c_i) = 0 \quad \text{für } i = 5, \dots, 10$$

Hasse Diagramm



→ Nebenbedingungen fürs lineare Programm:

$$\text{z.B.: } (a_2, a_5) \in P_{R_1} : u_5 + \varepsilon \leq u_2 \rightarrow \text{für jede Kante}$$

$$((a_6, a_{10}), (a_9, a_{11})) \in P_{R_2} : u_9 - u_{11} + \varepsilon \leq u_6 - u_{10}$$

→ optimale Lösung > 0 ? Gibt uns eine mögl. Repräsentation

Konsistenz überprüfen

Lass $A = \{a_1, \dots, a_n\}$ sein und betrachte das lineare Optimierungsproblem

$$E - \langle (0, \dots, 0, 1)', (u_1, \dots, u_n, \varepsilon)' \rangle \rightarrow \max_{(u_1, \dots, u_n, \varepsilon) \in \mathbb{R}^{n+1}}$$

unter den Nebenbedingungen:

$$- 0 \leq (u_1, \dots, u_n, \varepsilon) \leq 1$$

$$- u_p = u_q \quad \forall (a_p, a_q) \in I_{R_1}$$

$$- u_q + \varepsilon \leq u_p \quad \forall (a_p, a_q) \in P_{R_1}$$

$$- u_p - u_q + \varepsilon \leq u_r - u_s \quad \forall ((a_p, a_q), (a_r, a_s)) \in I_{R_2}$$

$$- u_r - u_s + \varepsilon \leq u_p - u_q \quad \forall ((a_p, a_q), (a_r, a_s)) \in P_{R_2}$$

→ λ ist konsistent, wenn die Lösung streng positiv ist.

Partiell kardinaler Nutzen in der Entscheidungstheorie

→ Wie definiert man Entscheidungskriterien?

- Kriterien, welche Repräsentationen von $\{E_\pi(u, \alpha) : (\underline{u}, \pi) \in U_A \times M\}$ nicht eindeutig
- ↳ Intervall- E
- Globale Kriterien, welche E -Admissibilität generalisieren (finde $\min 1(u, \pi)$ für das X erw. Nutzen max)
- Lokale Kriterien, welche Maximalität generalisieren (finde $\min 1(u_Y, \pi_Y)$ für alle $Y \in A$) für das X Y dominiert)

Daten-basierte Entscheidungen unter Credalmengen

Konjugierte Verteilungen

- neue Daten
- Priori \rightarrow Daten \rightarrow Posteriori \Rightarrow Bayes-Lernen
- ↳ neue Daten: Posteriori wird zur Priori
- \Rightarrow Posteriori ausrechnen etwas schwierig
- ↳ einfacher wenn konjugiert

Eine Vtlfamilie Π von A priori-Vtlf. heißt zu einer Menge P von SpVtlf. konjugiert, wenn für $\forall \pi_{t(x)} \in \Pi$ und für $\forall p_{t(y)} \in P$ die zugehörige Posteriori-Vtlf. wieder ein Element von Π ist.
→ Exponentialfam.: es ist möglich eine kog. Vtlf. zu konstruieren

- wir wollen nicht nur verallgemeinerte Prioris sondern verallgemeinerte Informationsstrukturen
- mögliche Gründe:
 - Robustheit: Umgebungsmodelle
 - Parameter-Intervalle
 - versch. Model Kandidaten
 - „big data uncertainty“

Umgebungsmodelle

- Motivation: Normal-Cauchy-Beispiel

- statt $p_{\theta}(\cdot)$ nutzen wir „ungefähr $p_{\theta}(\cdot)$ “
↳ Credalmenge aller Vtlf., nah an $p_{\theta}(\cdot)$ “

reguläre Intervallwertige
↓ Wkt.

$$F\text{-Wkt. } P_{\theta}(\cdot) = [L_{\theta}(\cdot), U_{\theta}(\cdot)]$$

$$L_{\theta}(A) = g(p_{\theta}(A)), \quad g: [0, 1] \rightarrow [0, 1]$$

Risikoeinschlag „central distr.“

↳ macht Werte etwas kleiner

- Datengestütztes Entscheidungsproblem unter credaler Informationsstruktur

datenfreies Entscheidungsprob. Menge von Wkt.
 $((A), (\Theta), \ell(\cdot, \cdot); (\chi, \sigma(\chi), (Q_{\chi_j}, j \in \Theta)))$
 credales statistisches Modell

$\rightarrow (\chi, \sigma(\chi), (p_{\chi_j}), j \in \Theta)$ mit $p_{\chi_j} \in Q_{\chi_j}$ für $\forall j \in \Theta$ heißt potentielles statistisches Modell bzgl. des credalen stat. Modells

\hookrightarrow cred. stat. Modell ist Menge von pot. stat. Modellen

Menge aller Entsch. fkt.

(D, Θ, R, \bar{R})

$$R: D \times \Theta \rightarrow \mathbb{R}; (d, \omega) \mapsto R(d, \omega) = \min_{p_{\chi_j} \in Q_{\chi_j}} \mathbb{E}_{p_{\chi_j}} \ell(d(\chi), \omega)$$

kleiner Erwartungswert

$$\bar{R}: D \times \Theta \rightarrow \mathbb{R}; (d, \omega) \mapsto \bar{R}(d, \omega) = \max_{p_{\chi_j} \in Q_{\chi_j}} \mathbb{E}_{p_{\chi_j}} \ell(d(\chi), \omega)$$

größer Erwartungswert

\hookrightarrow für jedes d kann ein anderes p_{χ_j} max/min sein

untere Risikofunktion
obere Risikofunktion

- verallgemeinerte Dominanzbegriffe (Vergleich bei festem ω_0)

- (lokale) Intervalldominanz $\frac{d_2}{d_1} > 1$

- (lokale) Intervallordnung $\frac{d_2}{d_1} > \frac{d_3}{d_4}$: beide Grenzen müssen schlagen

- Repräsentation zur Vorsicht $\eta \leftarrow$ je größer, desto mehr Gewicht auf oben
 \hookrightarrow reelle Zahlen bilden

$$d_1 \leq_{\eta} d_2 \Leftrightarrow \eta \cdot \bar{R}(d_1, \omega_0) + (1-\eta) R(d_1, \omega_0) \geq \eta \cdot \bar{R}(d_2, \omega_0) + (1-\eta) R(d_2, \omega_0)$$

\rightarrow Entsch. problem (D, Θ, R_{η}) betrachten

\hookrightarrow Zulässigkeit & Dominanzbegriff lässt sich verallgemeinern

- verallgemeinerte Entscheidungskriterien

\rightarrow mit (D, Θ, R_{η}) lassen sich alle Kriterien wie bisher anwenden

$\hookrightarrow \eta=1$: Betrachtung des jeweils max Risikos

Menge der potentiellen Risikofkt.

Menge von Risikofkt.

- anderer Ansatz: (D, Θ, \bar{R})

\hookrightarrow wir kriegen Menge von Lösungen

Spezialfall Testproblem

- betrachte worst-case Szenario: obere Risikofkt betrachten

- $\Theta = \{\omega_0, \omega_1\}$, Credalmengen $Q_{\omega_0}, Q_{\omega_1}$ (2 Credalmengen: ca. ω_0 vs. ca. ω_1)

- Aktionen: $A = a_0, a_1$

- Randomisierte Entscheidungsfkt. $d(x) = q(x) \cdot a_0 + (1-q(x)) \cdot a_1$

vollständig beschrieben durch Testfunktion $q(x)$

- 0-1 Verlustfunkt.: Risikofkt. entspricht Fehlerwkt.

- mengenwertige Fehlerwkt. 1. Art: $\{\mathbb{E}_{p_{\omega_0}}(\psi(x)) \mid p_{\omega_0} \in Q_{\omega_0}\}$; 2. Art: $\{\mathbb{E}_{p_{\omega_1}}(1 - \psi(x)) \mid p_{\omega_1} \in Q_{\omega_1}\}$

- obere Risikofkt. betrachtet max. Fehlerwkt.:

$$1. \text{ Art: } \bar{R}(d, \omega_0) = \max_{p_{\omega_0} \in Q_{\omega_0}} \mathbb{E}_{p_{\omega_0}} \psi(x) = \bar{E}_{Q_{\omega_0}} \psi(x)$$

$$2. \text{ Art: } \bar{R}(d, \omega_1) = \bar{E}_{Q_{\omega_1}} (1 - \psi(x)) = 1 - \bar{E}_{Q_{\omega_1}} \psi(x)$$

\Rightarrow Jetzt wie klassisches Problem

- Asymmetrische Tests: Niveau- α -Maximin-Test (Maximiere minimale Güte)

\hookrightarrow Betrachte nur Test mit $\bar{E}_{Q_{\omega_0}} \psi(x) \leq \alpha$

- Ungünstigstes Paar (q_0^*, q_1^*)

nimmt max Risiko unter H_0 und min Güte unter H_1 an

→ Likelihood-Ratio Test basierend auf ungünstigstem Paar ist der beste Test

↪ es existiert nicht zwingend ein ungünstiges Paar

- Huber - Strassen Theorie

Wenn die Risikozuschlagsfkt. convex ist existiert ein ungünstiges Paar

Datenbasierte Entscheidungsprobleme mit PRIORI-Credalmengen

- Sei SPmodell jetzt (meist) präzise
 - Verallgemeinertes Bayes - Risiko $E_M R(d, \pi)$
 - Kriterien & Algorithmen wie bisher
- } Verallgemeinerte Priori - Risiko - Optimalität
- Löse Entsch.prbl. mit Posteriori als aufdat. Priori
 - Kriterien & Algorithmen unmittelbar anwendbar
- } Posteriori - Loss - Optimalität

⇒ Hauptsatz der Bayes-Entscheidungstheorie im Allgemeinen nicht verallgemeinbar auf diese Situation
↪ die 2 Wege sind nicht äquivalent → inhaltliche Entscheidung

- Generalized Bayes Rule $M_{\cdot|x} = \{\pi(\cdot|x) \mid \exists \pi(\cdot) \in M : \pi(\cdot|x) \text{ ist Posteriori-Vtg. von } \pi \text{ geg. } x \text{ bzgl. } \pi(\cdot)\}$
↪ Bayes - Postulat: alle stat. Analysen haben sich ausschließlich auf $M_{\cdot|x}$ zu stützen

⇒ Robuste Bayes-Analyse in konjugierten Modellen

- Problem: wie weit Priori und SP auseinander liegen wird überhaupt nicht beachtet

↪ mit Intervallen arbeiten $[\underline{y}^{(0)}, \bar{y}^{(0)}]$ typischerweise intervallwertiger Priori - Lageparameter

↪ lässt man $\underline{y}^{(0)}$ und $\bar{y}^{(0)}$ gegen die Grenzen des zulässigen Priori-Parameterbereichs gehen, so erhält man „near ignorance“ Modelle

→ bei „nicht überraschenden“ Beobachtungen: Posteriori-Unschärfe klein

→ bei „überraschenden“ Beobachtungen: Posteriori-Unschärfe groß

Sozialwahltheorie

Wie können die individuellen Inputs der Mitglieder einer Gruppe zu einem für alle Mitglieder akzeptablen Gruppenoutput aggregiert werden?

- C : endliche Menge von Konsequenzen

- R : Menge aller reflexiven, vollständigen, transitiven Relationen $R \subseteq C^2$

- $n \in \mathbb{N}$: festgelegte Gruppengröße

→ $R := (R_1, \dots, R_n) \in R^n$: Präferenzprofil einer Gruppe der Größe n

⇒ Finde Regeln W , die jedem Präferenzprofil $R \in R^n$ eine bestimmten Eigenschaften genügende Gruppenordnung $W(R)$ zuweisen (jedem Präferenzprofil wird eine Präferenzrelation zugewiesen) ($W: R^n \rightarrow R$: Wohlfahrtsfunktion)

CONDORCET'S Methode

Zählen wie viele a vor b \rightarrow Mehrheit

„Die Gruppe bevorzugt Alternative a vor b, falls strikt mehrere Gruppenmitglieder dies ebenfalls tun. Platzieren ebenso viele Mitglieder a vor b wie b vor a, so ist die Gruppe indifferent.“

$$\Rightarrow \forall (a,b) \in C^2 : (a,b) \in Co(C) \Leftrightarrow |\{i : (a,b) \in R_i\}| \geq |\{i : (b,a) \in R_i\}|$$

\rightarrow wir können intransitive Zyklen erhalten \rightarrow keine Präferenzrelation

BORDAS Methode

Durchschnittliche Ränge berechnen

„Die Gruppe bevorzugt a vor b, falls der durchschnittliche Rang von a höher ist als der von b. Haben a und b den gleichen durchschnittlichen Rang, so ist die Gruppe indifferent.“

\hookrightarrow es können alle den gleichen durchschnittlichen Rang haben

Instant-Rundoff Methode (nach Thomas Hare)

Schließe Option mit wenigsten Erstplatz-Stimmen aus

„a ist mindestens so wünschenswert wie b, falls a auf der gleichen oder einer späteren Stufe ausgeschlossen wird.“

COOMB'S RULE (nach Clyde Coomb)

Wir schließen aus, was die meisten Mitglieder als letzten Platz wählen

„a ist mindestens so wünschenswert wie b, falls a auf der gleichen oder einer späteren Stufe ausgeschlossen wird.“

Axiome nach K. ARROW

1) UNANIMITY Wenn alle a besser als b finden, dann muss die Gruppenentscheidung das auch aussagen

2) INDEPENDENCE OF IRRELEVANT ALTERNATIVES (IAA)

Meinungs-
bildner

$$\begin{array}{l} \Rightarrow R = (R_1, R_2, R_3) \\ \Rightarrow Q = (Q_1, Q_2, Q_3) \end{array} \left. \begin{array}{l} R_1 \text{ rankt wie } Q_1 \\ R_2 \text{ --- --- } Q_2 \\ R_3 \text{ --- --- } Q_3 \end{array} \right\} \Rightarrow w(R) = w(Q)$$

\hookrightarrow Problem: rein ordinates Verständnis

3) NO DICTATORSHIP Es sollte kein Gruppenmitglied geben, das, egal welche Meinungen die anderen Gruppenmitglieder haben, das Ranking bestimmen kann

- Arrows Unmöglichkeitstheorem: Axiome sind nicht alle gleichzeitig erfüllbar

\rightarrow Condorcet erfüllt alle 3 Annahmen (ist aber keine Wohlfahrtsregel)

\hookrightarrow nicht mehr für beliebige Präferenzprofile (intransitive ausschließen) \rightarrow Condorcet ist Wohlfahrtsfkt.

MÖGLICHKEITSTHEOREM nach A. SEN

- Single-peakedness: Es existiert eine strikte Anordnung von C (z.B. politisches Spektrum), bzgl. derer die Präferenzkurven für alle R; nur einen Gipfel besitzen

- Single-peakedness: --- nur ein Tal besitzen

\Rightarrow Condorcet ist transitiv \Rightarrow erfüllt Axiome

